

Universidad  
Rey Juan Carlos

Escuela Técnica Superior  
de Ingeniería Informática

Grado en Ingeniería del Software

Curso 2023-2024

Trabajo Fin de Grado

**MÉTODOS DE APRENDIZAJE AUTOMÁTICO  
PARA LA CLASIFICACIÓN DE  
COMPORTAMIENTOS ESTEREOTIPADOS**

**Autor: Gonzalo Ortega Carpintero**  
**Tutor académico: Alberto Fernández Gil**  
**Tutora CSIC: Paula Peixoto Moledo**



# Agradecimientos

(Por redactar)



# Resumen

(Por redactar)

## **Palabras clave:**

- Python
- Neurociencia
- Aprendizaje automático
- ...



# Índice de contenidos

Índice de tablas	X
Índice de figuras	XII
Índice de códigos	XIV
<b>1. Introducción</b>	<b>1</b>
1.1. Bibliotecas y herramientas utilizadas . . . . .	2
<b>2. Objetivos</b>	<b>4</b>
<b>3. Fundamentos teóricos</b>	<b>5</b>
3.1. Métodos no supervisados . . . . .	5
3.1.1. Agrupamiento por K-medias . . . . .	6
3.1.2. Agrupación aglomerada . . . . .	7
3.1.3. Agrupación por afinidad . . . . .	7
3.1.4. Análisis de componentes principales . . . . .	8
3.2. Métodos supervisados . . . . .	8
3.2.1. Red neuronal . . . . .	8
<b>4. Análisis y experimentación</b>	<b>9</b>
4.1. Preprocesado de datos . . . . .	9
4.1.1. DeepLabCut . . . . .	13
4.1.2. Filtrado e interpolación . . . . .	13
4.1.3. Computo de variables a analizar . . . . .	14
4.2. Procesado de datos . . . . .	15
4.2.1. Matriz de similitud . . . . .	15
4.2.2. Agrupamiento por afinidad . . . . .	15
4.2.3. Reducción de dimensionalidad para visualización . . . . .	15
4.2.4. Entrenamiento de una red neuronal . . . . .	15
<b>5. Resultados</b>	<b>16</b>
<b>6. Conclusiones</b>	<b>17</b>

<b>Bibliografía</b>	<b>17</b>
<b>Apéndices</b>	<b>20</b>
<b>A. Este es el primer apéndice</b>	<b>22</b>
A.1. Ejemplo de sección . . . . .	22





# Índice de tablas

1.1. Enlaces a cuadernos de Google Colab. . . . .	2
4.1. Datos de las sesiones . . . . .	10
4.2. Datos de DeepLabCut . . . . .	10



## Índice de figuras

3.1. Datos artificiales . . . . .	7
4.1. Salida de DeepLabCut. . . . .	11
4.2. Trayectorias durante el preprocesado . . . . .	13



# Índice de códigos

3.1. Generación de datos sintéticos. . . . .	6
3.2. k-medias. . . . .	7
3.3. Propagación de afinidad. . . . .	7
3.4. Propagación de afinidad. . . . .	8



# 1

## Introducción

La Neurociencia es la disciplina científica que estudia el sistema nervioso y todas sus componentes. Para el estudio del funcionamiento del cerebro pueden utilizarse multitud de técnicas diferentes, pero para evitar la intrusión en el sujeto de estudio de muchas de ellas, muchos experimentos e investigaciones se basan en el estudio del comportamiento. Es la etología la encargada de este tipo de estudio en animales y en la cual, históricamente, la categorización de comportamientos dependía fuertemente de la observación manual. Eso ha conllevado siempre una excesiva cantidad de tiempo y las desventajas de los posibles errores de percepción humanos, limitando la cantidad y la calidad de los análisis a realizar.

Gracias a los recientes avances en algoritmos de aprendizaje automático, hoy en día es posible computar multitud de datos de forma simultánea, agilizando y automatizando análisis como el ilustrado previamente.

Este Trabajo de Fin de Grado se ha realizado a lo largo de una estancia de prácticas académicas en el Jercog's Team, un equipo de investigación perteneciente al Instituto Cajal, instituto de Neurociencia del Congreso Superior de Investigaciones Científicas. El equipo está centrado en el estudio de la memoria mediante experimentos con ratones, y uno de sus proyectos abiertos consistía en poder elaborar una herramienta para clasificar automáticamente los comportamientos estereotipados de los ratones. Estos son comportamientos cortos, repetitivos y con cierta tendencia a generar patrones, tales como rascarse, caminar en círculos o levantarse a dos patas, ejecutados sin ninguna finalidad, y usualmente inducidos por estar en entornos cerrados y artificiales.

Durante la estancia se han valorado multitud de técnicas de análisis y procesamiento de datos, haciendo hincapié en métodos de aprendizaje automático para



tratar de completar el proyecto gracias a los últimos avances en computación.

## 1.1. Bibliotecas y herramientas utilizadas

### DeepLabCut

DeepLabCut [1] es una herramienta para la estimación 2D y 3D sin marcadores mediante el uso de redes neuronales. Es capaz de identificar y rastrear diferentes partes del cuerpo de múltiples especies realizando todo tipo de comportamientos. Esta ha sido la base de todo nuestro trabajo, ya que todos los videos que hemos analizado han sido procesados en primer lugar por DeepLabCut para rastrear las posiciones de múltiples puntos de los animales a lo largo de los videos de las sesiones. Debido a su importancia, damos una explicación más en detalle de su funcionamiento y de como lo hemos utilizado en la sección 4.1.1.

### Google Colab

Google Colab es una herramienta para realizar cuadernos de Jupyter en línea, y poder ejecutarlos en el *backend* de Google. Estos son documentos que intercalan fragmentos de texto con fragmentos de código ejecutable en Python, así como la salida de las distintas ejecuciones. Todo el código realizado para este trabajo ha sido realizado en cuadernos de Colab, y puede ser consultado en los siguientes enlaces:

<b>Ejemplos teóricos</b>	<a href="https://colab.research.google.com/drive/1qL-LQTCFLZcqExN7qyYyRAT1nm7P8NhuK?usp=sharing">https://colab.research.google.com/drive/1qL-LQTCFLZcqExN7qyYyRAT1nm7P8NhuK?usp=sharing</a>
<b>DeepCutLab</b>	<a href="https://colab.research.google.com/drive/1dFb-mUcfW9el50v0RBCkLIItTD6SF7A3x?usp=sharing">https://colab.research.google.com/drive/1dFb-mUcfW9el50v0RBCkLIItTD6SF7A3x?usp=sharing</a>
<b>Análisis principal</b>	<a href="https://colab.research.google.com/drive/1ak2VpDi-zTnV-uEDp-viEkpa8GFDGuBR?usp=sharing">https://colab.research.google.com/drive/1ak2VpDi-zTnV-uEDp-viEkpa8GFDGuBR?usp=sharing</a>

Tabla 1.1: Enlaces a cuadernos de Google Colab.

### Scikit-learn

Scikit-learn [2] es una biblioteca de código abierto de Python que contiene numerosas implementaciones de algoritmos de aprendizaje automático. Hemos usado dichas implementaciones tanto como para la explicación teórica de los algoritmos, como para el análisis real de los datos de los animales.

## **pandas**

**pandas** es una biblioteca de manejo de datos mediante tablas denominadas **DataFrame**. Todos los datos que hemos cargado para ser analizados los hemos guardado como **DataFrames** para poder tener un fácil acceso a todos ellos y a sus variables pudiendo, además, visualizarlos de una forma sencilla.

## **NumPy**

**NumPy** es una de las bibliotecas principales de cálculo científico en Python. Proporciona un objeto de **array** multidimensional y numerosas funciones estadísticas y algebraicas de mucha utilidad.

## **matplotlib**

**matplotlib** es una biblioteca para crear figuras en Python. Todas las figuras de representación de datos que aparecen en este trabajo han sido creadas con **matplotlib**. El código concreto utilizado para generarlas puede consultarse en los cuadernos de Colab.

# 2

## Objetivos

(Provisional)

El objetivo de este trabajo es hacer una breve introducción a ciertas técnicas de aprendizaje automático aplicables al procesamiento de datos en el análisis de experimentos con animales. Para ello el trabajo se divide en dos capítulos principales.

En el primero abordaremos el estudio teórico de ciertos algoritmos de agrupamiento, reducción de dimensionalidad y de clasificación supervisada. Todo ello desde un punto de vista teórico con ejemplos fáciles de visualizar para ayudar al lector a comprender en profundidad los métodos.

En el segundo capítulo, desarrollaremos paso a paso el análisis real ejercido durante la estancia en el Instituto Cajal. El principal objetivo durante estos meses ha sido buscar la mejor forma de, dados una serie de videos de ratones en su caja, detectar automáticamente diferentes tipos de comportamientos. El fin último del proyecto es estudiar la posibilidad de clasificar dos grupos de animales, control y medicados, basándose en los comportamientos estereotipados.

Para el preprocesado de los videos se ha utilizado la herramienta DeepLabCut, que mediante el uso de redes neuronales y una relativamente pequeña muestra de entrenamiento computa una estimación de la posición de los animales en cada uno de los fotogramas. Tras el preprocesado haremos una revisión de los artículos científicos que han motivado las diferentes técnicas de agrupamiento que hemos acabado utilizando, y finalizaremos desarrollando cada una de ellas a la par que desglosando el código en Python utilizado en cada apartado.

# 3

## Fundamentos teóricos

### 3.1. Métodos no supervisados

Los algoritmos de aprendizaje automático no supervisados se utilizan cuando no se conoce la salida esperada. Al algoritmo de aprendizaje se le otorgan los datos de entrada y se le pide extraer información de estos datos. Las principales aplicaciones de estos algoritmos, las cuales vamos a aprovechar, son la agrupación de datos y la reducción de dimensionalidad de las variables de los mismos. Esa última es usada principalmente para poder hacer representaciones de datos multidimensionales, los cuales serían complejos de visualizar de otra forma.

La principal pega que pueden tener estos algoritmos es que, si bien no siempre son capaces de identificar conocimiento dados los datos utilizados, cuando lo obtienen, no siempre es el conocimiento que esperábamos obtener. Póngase el ejemplo de un algoritmo que tratase de agrupar rostros de personas iguales. Al no darle a priori ningún tipo de salida de ejemplo, el algoritmo puede acabar clasificando si los rostros están de frente o de lado, no precisamente lo que esperábamos. Es por ello que estos algoritmos cuentan con diversidad de parámetros para ajustarlos a nuestras necesidades, tratando de realizar la agrupación deseada.

En esta sección vamos a estudiar a fondo tres tipos de algoritmos de agrupación: el agrupamiento por k-medias, la agrupación aglomerada, y la agrupación por afinidad. Además, estudiaremos también el principal algoritmo de reducción de dimensiones, el análisis de componentes principales, PCA, de sus siglas en inglés. Los principales ejemplos y explicaciones de los algoritmos han sido inspirados

por los datos en el libro [3, Introduction to Machine Learning with Python].

Para analizar los diferentes métodos hemos utilizado `scikit-learn` para generar una muestra sintética de datos bidimensionales agrupados en dos lunas.

Código 3.1: Generación de datos sintéticos.

```

1  X, y = skl.make_moons(n_samples=200,
2                          noise=0.05,
3                          random_state=0)
4
5  def figure_scatter_data(data, assignment=None):
6      fig = plt.figure(figsize=(5, 5))
7      ax = fig.add_subplot(111)
8      if assignment is not None:
9          ax.scatter(data[:, 0], data[:, 1], c=assignment, cmap='
              Pastel1')
10     else:
11         ax.scatter(data[:, 0], data[:, 1], alpha=0.5)
12
13     ax.set_xlabel('X')
14     ax.set_ylabel('Y')
15
16     figure_scatter_data(X)

```

En la tabla 1.1 está el enlace para poder ejecutar el código en el *backend* de Google.

### 3.1.1. Agrupamiento por K-medias

El algoritmo de k-medias clasifica los datos separando los datos en  $n$  grupos de con la misma varianza.

El algoritmo comienza inicializando aleatoriamente  $n$  centroides, siendo  $n$  el número de agrupaciones que se le han dicho que realice. Estos centroides serán los centros de las agrupaciones que va a realizar, no tienen por qué pertenecer a los datos, pero sí que están contenidos en su misma dimensión. En cada iteración, el algoritmo asigna a cada punto de los datos el centroide más próximo y luego asigna a cada agrupación un nuevo centroide calculado como la media de los datos que se han asignado a dicha agrupación.

Formalmente, el algoritmo divide un conjunto de  $n$  puntos  $x$  en  $k$  agrupaciones disjuntas  $C$ , cada una descrita por la media  $\mu_j$  de los puntos en la agrupación. Para ello, el algoritmo trata de encontrar los centroides que minimicen




Figura 3.1: Datos artificiales en forma de dos lunas para probar los diferentes tipos de agrupaciones.

$$\sum_{i=0}^n \min_{\mu_j \in C} (||x_i - \mu_j||^2) \quad (3.1)$$

El algoritmo finaliza cuando una iteración no realice ninguna modificación de las agrupaciones.

Código 3.2: k-medias.

```
1 kmeans = KMeans(n_clusters=2, n_init="auto")
2 kmeans_assignment = kmeans.fit_predict(X)
```

### 3.1.2. Agrupación aglomerada

Código 3.3: Propagación de afinidad.

```
1 agg = AgglomerativeClustering()
2 agg_assignment = agg.fit_predict(X)
```

### 3.1.3. Agrupación por afinidad

El algoritmo de propagación de afinidad crea agrupaciones mandando mensajes entre pares de puntos hasta que converge. La principal cualidad de este

algoritmo es que, a diferencia con la mayoría de algoritmos de agrupamiento, no necesita saber el número de agrupaciones a realizar de antemano, sino que las genera dinámicamente.

Código 3.4: Propagación de afinidad.

```
1 aff = AffinityPropagation()  
2 aff_assignment = aff.fit_predict(X)
```

### 3.1.4. Análisis de componentes principales

## 3.2. Métodos supervisados

[4, Deep Learning with PyTorch]

### 3.2.1. Red neuronal

# 4

## Análisis y experimentación

### 4.1. Preprocesado de datos

Los datos de los que hemos partido para realizar el análisis han sido 88 pares de videos en blanco y negro, de unos cinco minutos cada uno, de ratones en su caja sin estar realizando ninguna tarea concreta. Cada par de videos consistía en un video de la vista cenital de la caja y otro de la vista lateral, como se puede observar en la Figura 4.1. Además, de cada par de videos teníamos el código del animal que estaba siendo grabado, la fecha de la sesión y si el animal estaba bajo los efectos del tratamiento de MDMA en dicha fecha o no. Mostramos un resumen de estos datos en la Tabla 4.1.

Para tratar de averiguar de forma automática el tipo de tratamiento de cada sesión, podríamos entrenar una red neuronal utilizando directamente los videos como datos de entrenamiento. Sin embargo, no contamos con una cantidad muy elevada de videos para entrenar, y además esto no nos daría ninguna pista sobre como comportamientos concretos se relacionan con el tratamiento. Al no contar con una base de datos de fragmentos de videos clasificados según el comportamiento del animal, tampoco podemos entrenar una red para distinguir estos comportamientos sin tener que pasar antes por un seguramente tedioso periodo de etiquetado manual de fragmentos. Por ello,



Video	Código del animal	Fecha de la sesión	Tratamiento
1	4128	2020-12-02	CONTROL
2	4128	2020-11-21	CONTROL
3	4128	2020-11-23	CONTROL
...	...	...	...
80	4108	2020-09-25	NMDA
81	4089	2020-09-18	NMDA
82	4089	2020-09-12	CONTROL
83	4089	2020-09-24	NMDA

Tabla 4.1: Fragmento del `DataFrame` que almacenaba los datos de las sesiones, incluyendo el número del video según se almacenaban en memoria, el código del animal, la fecha de la sesión y el estado del tratamiento.

	Nosex	Nosey	Noselikelihood	Headx	Heady	...
0	136.165344	177.722496	0.000084	129.790253	174.772552	...
1	162.032005	201.444756	0.942181	168.152061	202.420639	...
2	156.297043	200.326378	0.000073	162.436028	203.156837	...
3	155.370415	199.043297	0.000277	159.507599	200.199928	...
4	149.272644	197.677170	0.000045	155.493912	198.814835	...
...	...	...	...	...	...	...

Tabla 4.2: Extracto del `DataFrame` de `pandas` de los datos sin procesar de DeepLabCut. Para cada punto rastreado, y para cada fotograma del video, se computa la predicción de la coordenada  $x$  y de la coordenada  $y$  y se da la verosimilitud de dicha predicción.

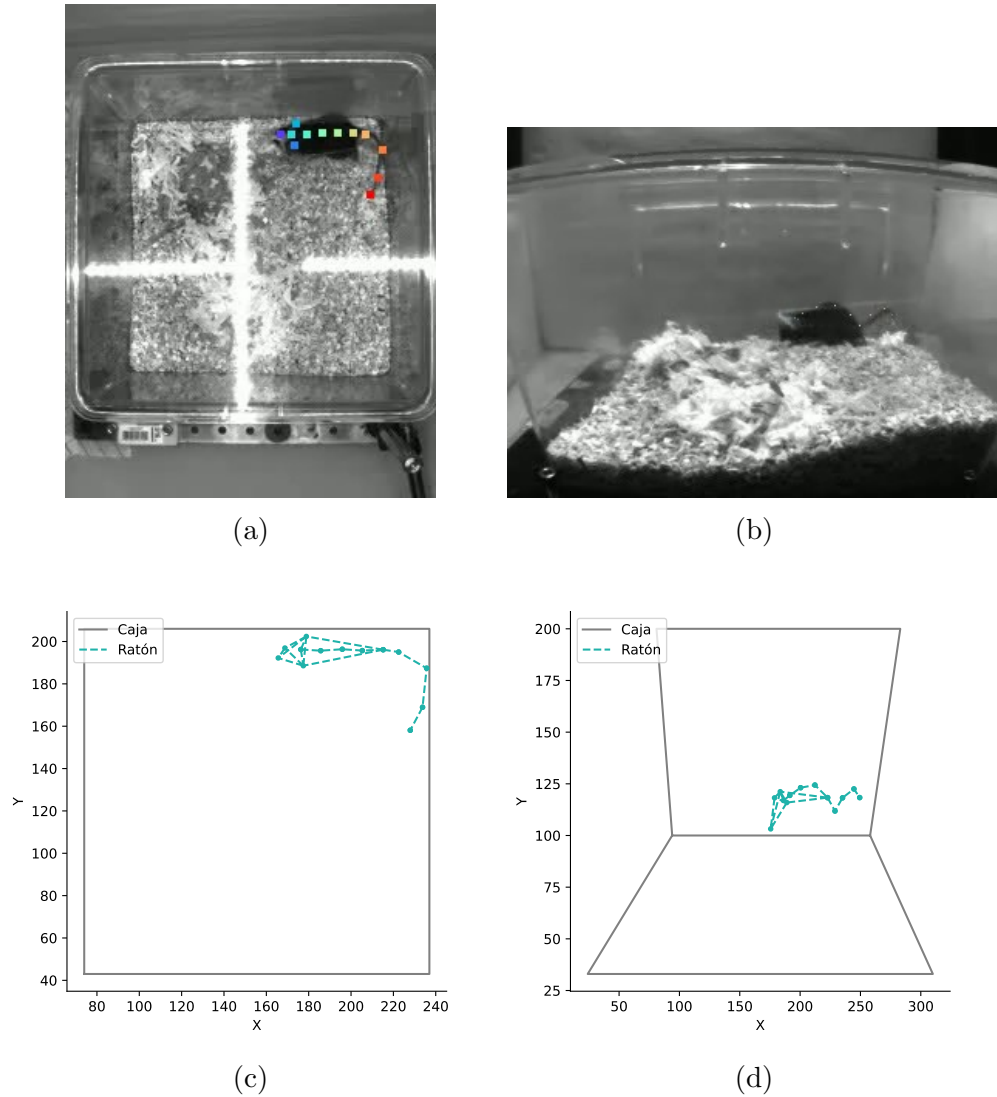



Figura 4.1: Salida de DeepLabCut del animal 4128 el 02-12-2020, 1:00:37. [4.1a](#) Video de la vista cenital de la caja. Los puntos sobre el animal son los dibujados por DeepCutLab para rastrear las partes del animal. [4.1b](#) Video de la vista lateral de la caja.




### 4.1.1. DeepLabCut

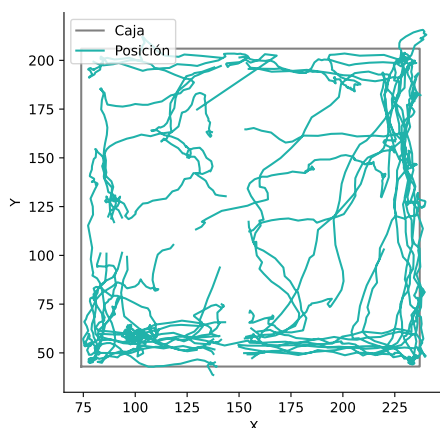
### 4.1.2. Filtrado e interpolación




(a)




(b)




(c)



(d)



(e)



(f)

Figura 4.2: Vistas cenital y lateral de trayectorias de un punto de la cabeza del animal. Datos correspondientes a los dos primeros minutos de la sesión del 2020-12-02 del animal 4128. 4.2b: Vista cenital de los datos antes del preprocesado. En la imagen se puede observar la gran cantidad de datos que se generan en la sesión de trabajo.

### **4.1.3. Computo de variables a analizar**

## **4.2. Procesado de datos**

### **4.2.1. Matriz de similitud**

### **4.2.2. Agrupamiento por afinidad**

### **4.2.3. Reducción de dimensionalidad para visualización**

### **4.2.4. Entrenamiento de una red neuronal**

# 5

## Resultados

(Por redactar)

# 6

## Conclusiones

(Por redactar)



# Bibliografía

- [1] A. Mathis, P. Mamidanna, K. M. Cury, T. Abe, V. N. Murthy, M. W. Mathis, and M. Bethge, “Deeplabcut: markerless pose estimation of user-defined body parts with deep learning,” *Nature Neuroscience*, 2018. [Online]. Available: <https://doi.org/10.1038/s41593-018-0209-y>
- [2] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [3] A. C. Müller and S. Guido, *Introduction to Machine Learning with Python*. O’Reilly, 2017.
- [4] E. Stevens, L. Antiga, and T. Viehmann, *Deep Learning with PyTorch*. Manning, 2020.



# Apéndice





Este es el primer apéndice

### **A.1. Ejemplo de sección**

Sección del apéndice